



UNIVERSIDADE FEDERAL DE SANTA CATARINA
DEPARTAMENTO DE ENGENHARIA ELÉTRICA E ELETRÔNICA

José Augusto Arbuseri - 13204572
Tulio Gomes Pereira - 14106069

Controle de um conversor Boost para Rastreamento de Ponto de Máxima potência (MPPT) Aplicado em Painéis Fotovoltaicos

Florianópolis
2018

Introdução

Devido a crescente busca por fontes de energia renováveis, a consolidação da tecnologia fotovoltaica como uma fonte viável de geração de energia elétrica vem ocorrendo vagarosamente ao longo de quase dois séculos de história, sendo marcada pelo surgimento de materiais mais eficientes voltados à foto-conversão, redução dos custos e elevação acentuada da produtividade.

A expansão da tecnologia fotovoltaica, que cresce exponencialmente desde a década de 70, pode ser atribuída a três aspectos distintos: o primeiro refere-se à melhora significativa dos materiais empregados na fabricação de células fotovoltaicas. Atualmente, além do Silício, que é o material utilizado em maior escala para a referida finalidade, uma gama bastante ampla de materiais vem sendo disponibilizada, permitindo o aperfeiçoamento, não apenas em termos de eficiência de conversão, mas também em flexibilidade, peso e custos.

Na maior parte das aplicações, circuitos eletrônicos são utilizados com o objetivo de processar os níveis de tensão e corrente de entrada, tornando-os adequados para alimentar uma carga específica. No caso de cargas em corrente contínua, são utilizados os conversores CC-CC e, no caso de cargas em corrente alternada, os conversores CC-CA. Em muitas aplicações, o conversor é utilizado entre o painel fotovoltaico e a carga, não para mantê-la adequadamente alimentada, mas sim para permitir que o painel atue sempre no ponto de máxima transferência de potência. Este tipo de aplicação é tão importante que, na literatura, os conversores utilizados com esta finalidade são especialmente denominados de rastreadores de máxima potência.

Porém, como a potência fornecida por células solares dependem de grandezas independentes como a radiação solar incidindo sobre a célula, e a temperatura ambiente, e a forma como o material é depositado durante a fabricação do painel, fazem com que exista uma dificuldade no controle do circuito de rastreamento da potência na grande maioria das aplicações, já que os valores de tensão e corrente que podem ser fornecidos pelas células, não sejam obtidos de forma linear, dificultando o encontro de um ponto ótimo para a potência.

Sendo assim, este projeto visa utilizar uma técnica de aprendizado de máquina através de redes neurais, buscando um modelo, que após treinado, possa ser utilizado para se alcançar o ponto de máxima potência do painel solar utilizando dos dados de radiação e temperatura, portanto serão comparados diversos formatos de redes, assim como variações dos possíveis dados de entrada, para se verificar o desempenho do modelo e se levantar uma comparação entre a utilização desta técnica, com técnicas de varredura, como é a “perturba e observa” que são as mais utilizadas atualmente para a realização desta tarefa.

- **Geração do Sistema**

O sistema de geração de energia fotovoltaica é mostrado de maneira completa na Figura 1. O sistema é dividido em três partes que serão explicadas na sequência: Pannel Solar, Conversor CC-CC, Estratégia de controle clássica e a proposta neste trabalho.

Arranjo Fotovoltaico

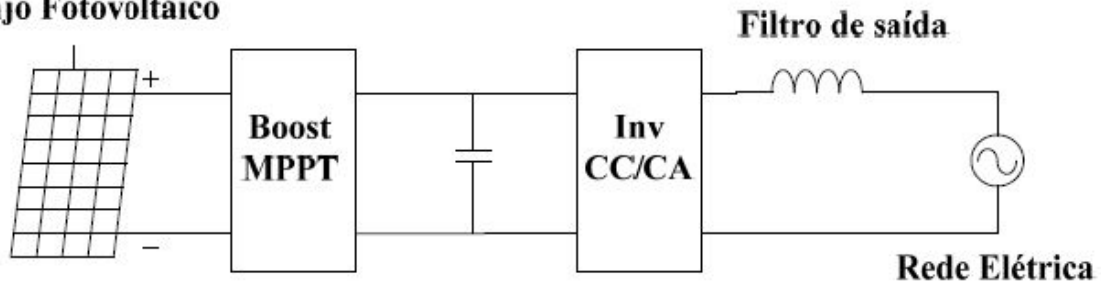


Fig. 1 – Sistema de geração de energia fotovoltaica conectada a rede elétrica.

Este trabalho tem por objetivo apresentar o arranjo fotovoltaico conectado a um rastreador de máxima potência, mostrando suas características, analisando a influência de fatores externos no seu funcionamento, modelando e validando seu modelo por meio de simulações. Assim de forma a simplificar o modelo da Fig.1 apresentamos o modelo utilizado em simulação deste projeto, ver Fig. 2.




Fig. 2 – Sistema simplificado de geração de energia fotovoltaica.

- **Paineis Solares**

Os painéis fotovoltaicos reúnem características tanto de uma fonte de corrente Fig. 3 (a) quanto de uma fonte de tensão Fig. 3 (b). Idealmente um painel fotovoltaico deveria ser capaz de fornecer uma corrente fixa intrínseca às suas propriedades físicas, enquanto a tensão em seus terminais fosse menor que sua tensão de circuito aberto. Porém, na prática, existem perdas no painel que fazem com que a sua capacidade de fornecer corrente diminua conforme a tensão em sua saída se aproxima da tensão de circuito aberto. Essa característica pode ser vista na Fig. 3 (c).




Fig. 3 - Características do painel fotovoltaico

Multiplicando a tensão pela corrente do painel ponto a ponto, obtém-se a curva de potência na saída do painel. Da Fig. 4 fica evidente que existe um ponto onde o painel tem sua máxima potência transmitida. Como a eficiência dos painéis fotovoltaicos fabricados em série até hoje é muito baixa, e desejável que, sempre que possível ele opere em seu rendimento máximo. No decorrer desse trabalho serão demonstradas algumas formas de alcançar isso.




Fig. 4 - Curva demonstrando o ponto de máxima transferência de potência no painel.

- **Influência de parâmetros ambientais nas curvas de geração**

Alguns fatores ambientais acabam tendo uma grande influência sobre a potência gerada pelo arranjo fotovoltaico. Os dois mais importantes são a temperatura e a irradiância solar. A seguir será abordado como cada um deles influi na geração.

A irradiância solar relaciona a energia solar por unidade de área, com isso fica explícito perceber que a energia gerada pelo painel será proporcional a esse parâmetro. Na Fig. 5 pode-se verificar que quanto maior a irradiância, maior a energia gerada pelo painel. Porém, nota-se que a tensão no ponto de máxima potência (V_{mp}) não mudou com a alteração desse fator.




Fig. 5 - Influência da irradiância na potência gerada pelo painel.

Outro ponto de grande influência é a temperatura. No decorrer do texto ver-se-á que a célula fotovoltaica tem as propriedades físicas parecidas com a de um diodo, elemento que diminui a sua tensão conforme o aumento da temperatura. Para muitos circuitos que usam diodo essa característica é interessante, pois isso acaba reduzindo as perdas no componente. Para um painel fotovoltaico esse acaba sendo um efeito indesejado, já que, quanto menor a tensão em seus terminais, menor será a energia gerada.




Fig. 6 - Influência da temperatura na potência gerada pelo painel.

O modelo de uma célula fotovoltaica é mostrada na Fig. 7. A corrente gerada pela interação fóton-elétron na Fig. 7 é representada como uma fonte de corrente constante I_L na Fig. 7. A junção pn, característica do Silício extrínseco na representação física, é modelada como um diodo D de junção pn no circuito elétrico. Os parâmetros de perdas associados à célula fotovoltaica real, em que a resistência paralela R_{sh} representa as perdas internas ou por correntes de fuga, enquanto a resistência série R_s retrata as perdas causadas devido às quedas de tensão nos contatos metálicos.




Fig. 7 - Modelo elétrico física da célula fotovoltaica.

No software Simulink existe um bloco PV array onde podemos usar modelos de painéis comerciais e setar configurações diversas de associação série/paralelo, e ainda setar qualquer parâmetro relativo às características construtivas do painel, ver Fig. 8.

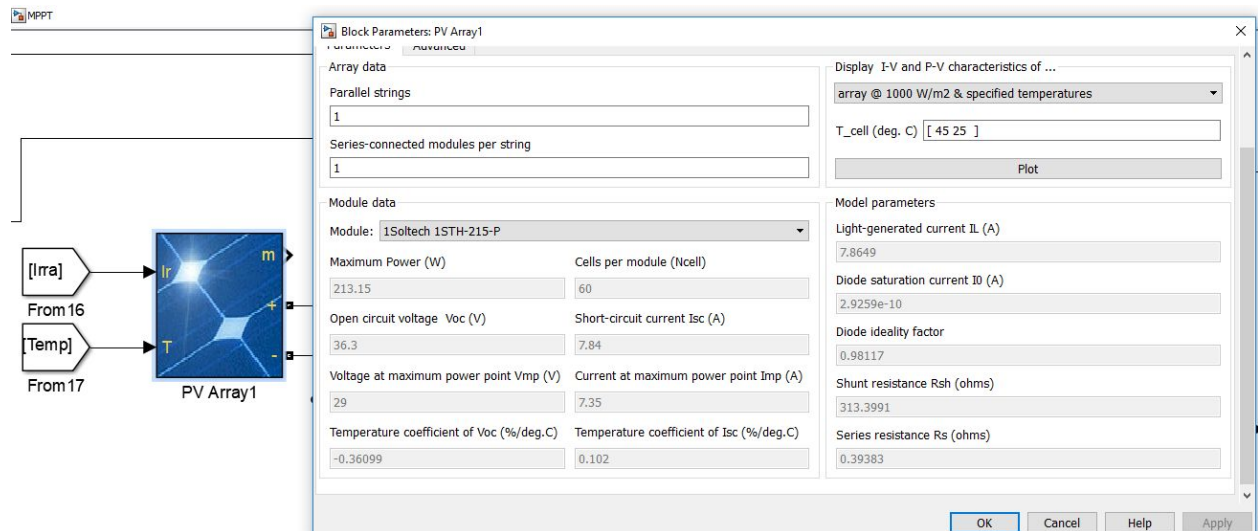


Fig. 8 - Modelo painel Simulink.

Ainda nessa ferramenta é possível plotar a corrente do painel e potência em função das variações de irradiação e de temperatura, esse painel usado na simulação possui uma máxima potência de 215W na condição 1000W/m² e temperatura de 25° Celsius. A fig. 9 mostra os pontos de máxima potência para as temperaturas de (80° 40° 20°) e a Fig. 10 mostra os pontos de máxima potência para irradiações de (1000, 800 e 300) W/m².




Fig. 9 - Pontos de máxima potência para diferentes temperaturas.




Fig. 10 - Pontos de máxima potencia para diferentes irradiações.

- **Conversores DC-DC**

Esta seção trata-se de uma revisão teórica do conversor CC-CC elevador de tensão denominado conversor Boost. Por ser um conversor elevador, a tensão de saída é necessariamente maior que a tensão de entrada, podendo ser no mínimo igual a esta.

Para processar a energia proveniente de uma fonte de tensão, o conversor Boost utiliza-se de um indutor em série com a fonte de alimentação, portanto, a fonte de alimentação do conversor tem características de fonte de corrente nesta topologia. Visto isso, para que seja possível processar esta energia, a carga deve possuir características de fonte de tensão. A topologia do Boost pode ser vista na Fig. 12.




Fig. 12 - Topologia do conversor Boost

Para a análise inicial, como a chave opera com altas frequências de comutação, considera-se a corrente no indutor constante. Na primeira etapa de operação, o interruptor S encontra-se fechado, gerando um curto-circuito na fonte com o indutor, portanto, toda a corrente I_L passa através do interruptor S. O diodo é reversamente polarizado, com tensão $-V_o$. Dessa maneira, o diodo D encontra-se aberto. A Fig. 11 ilustra a primeira etapa de operação.




Fig. 11 - Primeira Etapa de operação.

Na segunda etapa de operação o interruptor S encontra-se aberto, a tensão sobre o mesmo é V_o e sua corrente é nula. Toda a corrente I_L atravessa o diodo D , portanto a fonte de entrada passa a entregar energia à carga. A Fig. 12, ilustra a segunda etapa de operação.




Fig. 12 - Primeira Etapa de operação.

O perfil da corrente e da tensão sobre os componentes do conversor podem ser vistos na Fig. 13.

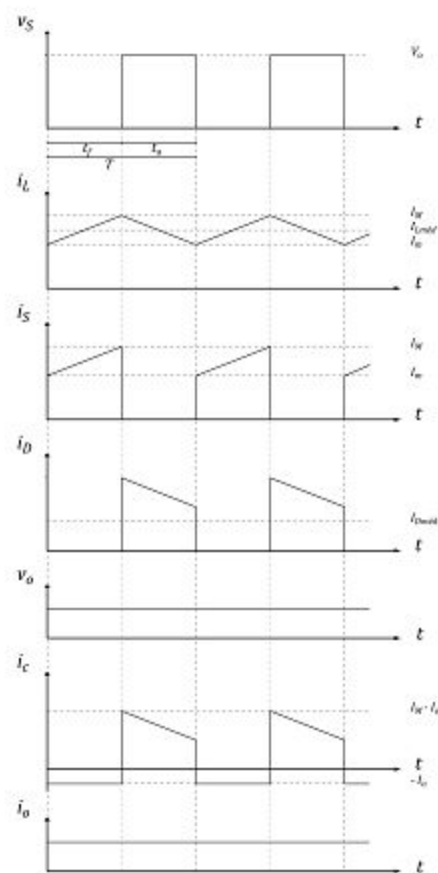


Fig. 12 - Corrente e tensão nos elementos do conversor durante as duas etapas de operação.

A partir de algumas manipulações triviais chegamos na equação que representa o ganho estatico do conversor Boost, ela é dada por:

$$\frac{V_o}{V_{in}} = \frac{1}{1-D}$$

Onde D é denominado razão cíclica.

De maneira semelhante podemos modelar a resistência de entrada do conversor Boost, assim chegamos no seguinte valor de resistência:

$$R_{ei}(D) = (1-D)^2 \cdot R_{carga}$$

De forma simples, a resistência efetiva de entrada $R_{ei}(D)$ pode ser entendida como uma resistência variável, cujo valor depende da resistência de carga R e da razão cíclica D , chegando na representação da Fig. 13.




Fig. 13 - Representação da resistência de entrada vista pelo painel fotovoltaico.

Assim a partir da razão cíclica podemos controlar a impedância de entrada vista do painel fotovoltaico por consequência podemos alcançar a máxima transferência de energia quando as impedâncias dos mesmos está casadas. A Fig. 14 mostra a região de operação do conversor boost, sua impedância varia de 0 até R_o assim ele possui uma região limitada de operação.




Fig. 14 - Regiões de operação estipulada para o conversor Boost operando como MPPT.

Conforme verificado na Fig. 15, para os conversores Buck-Boost, Cúk, Sepic e Zeta não há região proibida, ou seja, a característica estática de ganho G_V destes conversores permite que o ângulo de inclinação da curva de carga varie entre 0° e 90° . Assim, a utilização de um destes conversores CC-CC como MPPT permitirá a operação do sistema sempre no ponto de máxima potência.

Conversor	G_V	$R_{ei}(G_V)$	$\theta_{R_{ei}}(G_V)$	Limites de $\theta_{R_{ei}}(D)$
Buck	D	$R_{ei}(G_V) = \frac{R_{carga}}{G_V^2}$	$\theta_{R_{ei}}(G_V) = \text{atan}\left(\frac{G_V^2}{R_{carga}}\right)$	$0^\circ < \theta_{R_{ei}}(D) < \text{atan}\left(\frac{1}{R_{carga}}\right)$
Boost	$\frac{1}{1-D}$	$R_{ei}(G_V) = \frac{R_{carga}}{G_V^2}$	$\theta_{R_{ei}}(G_V) = \text{atan}\left(\frac{G_V^2}{R_{carga}}\right)$	$\text{atan}\left(\frac{1}{R_{carga}}\right) < \theta_{R_{ei}}(D) < 90^\circ$
Buck-Boost, Cúk, Sepic e Zeta	$\frac{D}{1-D}$	$R_{ei}(G_V) = \frac{R_{carga}}{G_V^2}$	$\theta_{R_{ei}}(G_V) = \text{atan}\left(\frac{G_V^2}{R_{carga}}\right)$	$0^\circ < \theta_{R_{ei}}(D) < 90^\circ$

Fig. 15 - Regiões de operação para demais conversores.

- **Técnicas clássicas.**

O projeto de um rastreador de máxima potência vai além da utilização de um conversor CC-CC e um microcontrolador para execução dos algoritmos de rastreamento, de forma que alguns dispositivos e circuitos auxiliares se fazem necessários, dos quais se citam: sensores, circuitos condicionadores de sinal, hardware do microcontrolador e circuito de comando, conforme mostra a Fig. 16.




Fig. 16: Conversor Boost e circuitos auxiliares.

Simplificadamente, a partir da leitura da tensão painel V e corrente painel I de saída do painel fotovoltaico, via sensores, o circuito de condicionamento gerará os sinais V e I que serão aplicados ao microcontrolador para execução dos programas voltados à busca pelo MPP.

O método Perturba e Observa (P&O) é bastante difundido na literatura, sendo um dos primeiros a considerar os sinais de tensão V e corrente I para realizar o rastreamento do ponto de máxima potência. O fluxograma do P&O pode ser visto na Fig. 17.

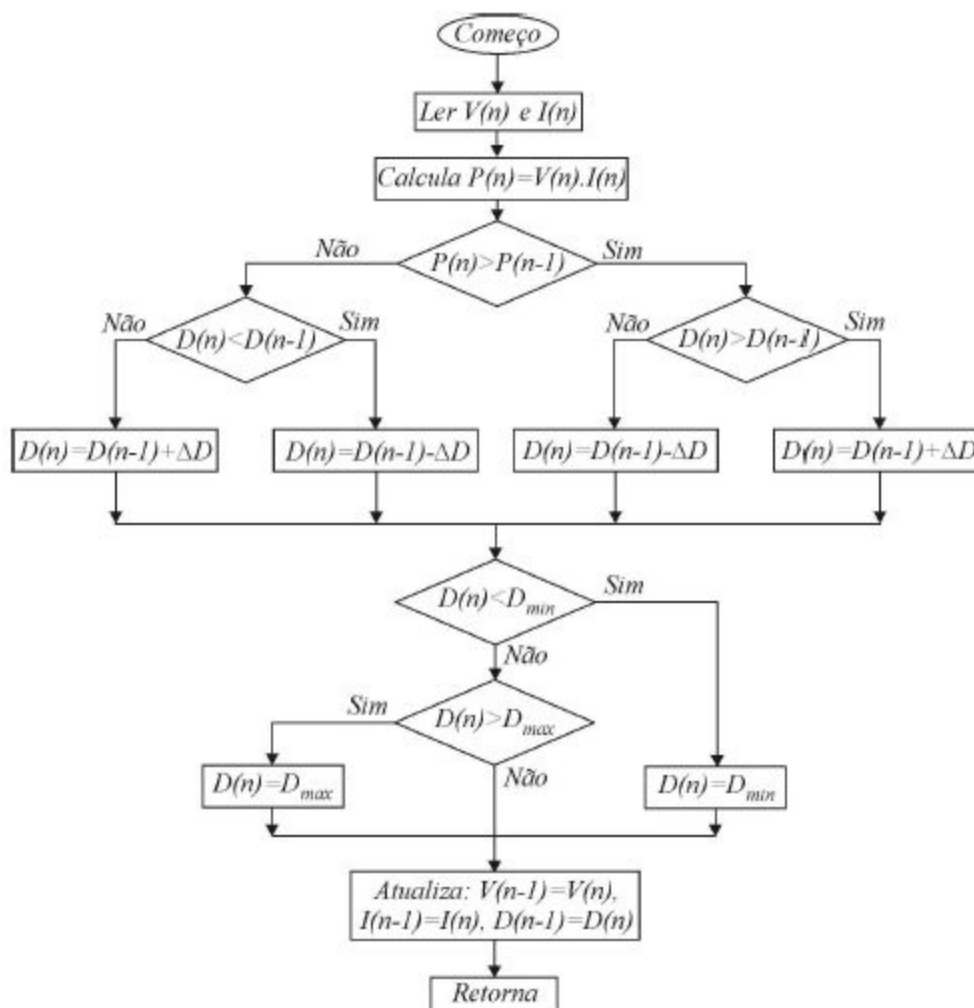


Fig. 17 - Fluxograma da técnica de rastreamento P&O.

O algoritmo, baseado nas curvas características da Fig. 18, trata-se de um método de perturbação e observação em que é aplicado um pequeno aumento no duty-cycle (D), e verificado a variação da potência. Caso ocorra aumento da potência fornecida pelo painel, o algoritmo segue com perturbações no mesmo sentido. No entanto, caso ocorra decréscimo de potência, na próxima iteração a perturbação irá acontecer no sentido contrário. A Fig. 18 mostra o compromisso entre velocidade de rastreo e a oscilação em regime permanente dessa técnica de rastreo.

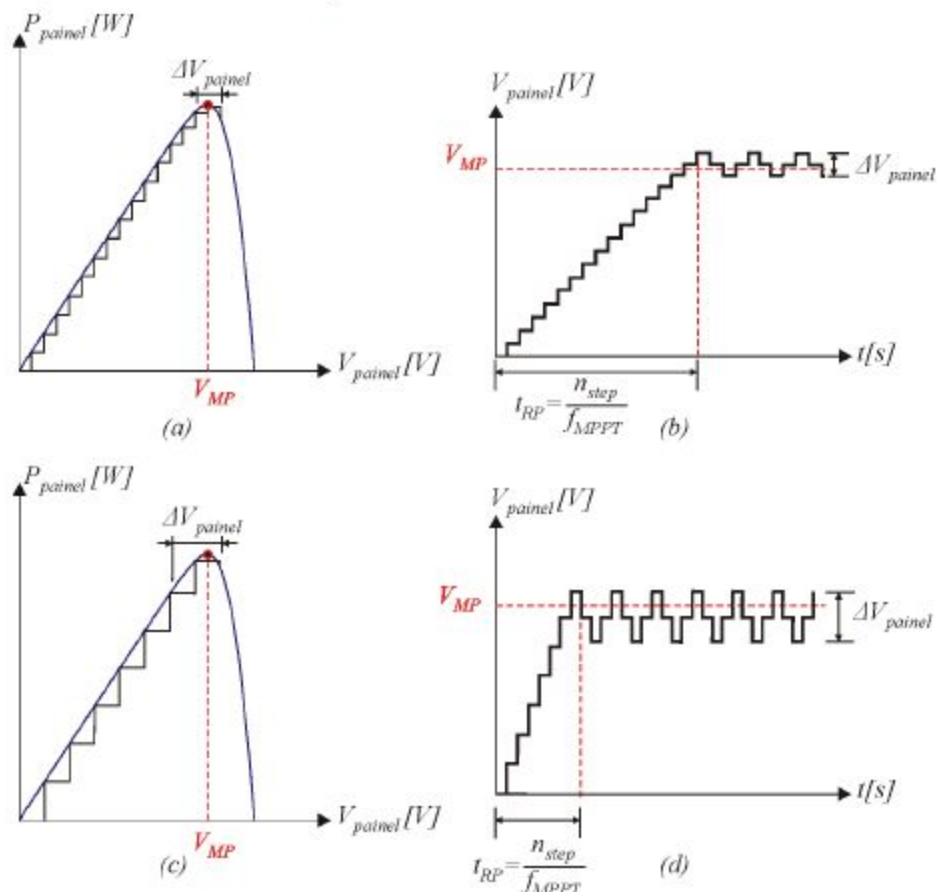


Fig. 18 - Comparação entre o rastreamento de máxima potência para diferentes valores do passo Delta D : (a) e (b) Passo reduzido; (c) e (d) Passo elevado.

Metodologia

Nessa seção será discutido a metodologia usada para adquirir o dataset, treinar as redes neurais e fazer as simulações passo a passo, mostrando as dificuldades e as soluções. Todo o desenvolvimento pelos autores está disponível no GITHUB (https://github.com/Jarbugeri/MPPT-Neural_Network) para que possa ser usado no futuro por outras pessoas em seus trabalhos.

• Geração do Data-Set

Visto a dificuldade dos autores em encontrar um DataSet, foi decidido gerar o próprio conjunto de dados para treinamento das redes neurais. Para gerar o dataset usou-se o simulador simulink e usando a técnica Perturba e Observa, similar ao que foi feito no artigo [2]. Para simular usou o circuito da Fig. 19. Usando o bloco signal builder mostrado na Fig. 19 foi gerado as entradas de irradiação e temperatura aleatórias para simular um ambiente.

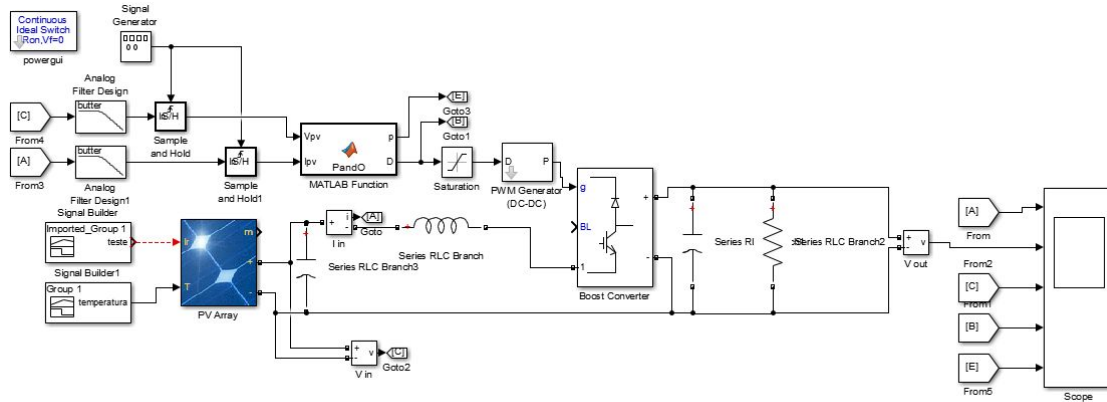


Fig. 19 - Circuito usado para gerar o dataset

Para gerar os dados de irradiação e temperatura fez um gerador de dados aleatórios como mostra a Fig. 20. A formatação do banco de dados foi organizada de maneira que o Signal builder pude-se interpretar os dados. A Fig. 20 mostra a criação de 1000 valores com variação entre 300 a 1000 W/m² e de 10° a 60° para a temperatura.

```

1 - s = 1000; %amostras geradas
2 -
3 - radiacao.time = zeros(s*2,1);
4 - radiacao.signals.values = zeros(s*2,1);
5 - radiacao.signals.dimensions = 1;
6 - radiacao.signals.label = 'teste';
7 - radiacao.time(1) = 0;
8 - radiacao.signals.values(1)= 1000;
9 - radiacao.signals.values(2)= 1000;
10 - for i = 2:2:s*2-1
11 -     radiacao.time(i) = (i)/2;
12 -     radiacao.time(i+1) = (i)/2;
13 - end
14 - for i = 3:2:s*2
15 -     rando = randi([300,1100],1,1) ;
16 -     radiacao.signals.values(i)= rando;
17 -     radiacao.signals.values(i+1)= rando;
18 - end
19 - radiacao.time(2000) = 1000;
20 - save radiacao.mat radiacao

```

Fig. 20 - Circuito usado para gerar o dataset de temperatura e irradiação.

A partir desse código chegamos no dataset de irradiação e temperatura para poder gerar os valores de corrente de entrada, tensão de entrada e duty-cycle para o ponto de máxima potência usando o método perturba e observa, ver Fig. 21




Fig. 21 - Dataset de Temperatura e Irradiação.

Após isso deixo o simulador rodando e exportando os dados a cada 0.25 segundo, usando o block Data to Workspace do simulink, esses dados exportados para o workspace são nosso dataset completo. A Fig. 22 mostra os pontos de degrau na temperatura e irradiação, então espera-se o transitório e amostra-se os dados relativos a máxima transferência de potencia.




Fig. 22 - Dataset de Temperatura e Irradiação.

Como pode ser visto na Fig. 22 a cada 1 segundo tem step de temperatura e irradiação mas eles estão defasado de 0,5 segundo, e a amostragem é feita a cada 0,25 para que seja descartado o transitório.

Assim foi gerado um dataset com 2093 linhas e 7 colunas, sendo que as colunas representavam respectivamente a corrente de entrada, tensão de saída, tensão de entrada, o duty-cycle, a potência, a irradiação e a temperatura.

- **Redes Neurais**

Sistemas baseados em Inteligência Artificial (IA) tem sido desenvolvidos e vem demonstrando resultados promissores e flexíveis, inúmeros trabalhos demonstram aplicações em diversas áreas da engenharia, juntamente com um domínio de pesquisa multidisciplinar, envolvendo além de engenharia, física, matemática, biologia, neurofisiologia, etc.

As redes neurais são uma das ferramentas que constituem a inteligência artificial, elas podem ser definidas como um mapeamento não linear de um vetor de espaço de entrada para um vetor de espaço de saída, que pode ser feito através de camadas de funções de ativação, ou neurônios, nos quais coordenadas de entrada são somadas de acordo com o valor de seus respectivos pesos e “bias” para reproduzir uma saída simples, ativada ou não de acordo com o respectivo nível de disparo.

Este tipo de sistema recebeu esta denominação devido a sua inspiração biológica nas unidades funcionais que constituem o cérebro, chamadas de neurônios, que são capazes de emitir pulsos elétricos em resposta a estímulos. Essas unidades são densamente interconectadas, resultando em uma arquitetura altamente complexa. Devido a esta arquitetura complexa, vários modelos matemáticos de neurônios artificiais foram desenvolvidos, refletindo o conhecimento biológico sobre o funcionamento do cérebro humano.

Um neurônio artificial, é uma estrutura que busca simular a forma e o comportamento das funções de um neurônio biológico. Assim, os dendritos são substituídos por entradas, cujas ligações com o corpo celular artificial são realizadas através de elementos chamados de peso. Os estímulos são captados pelas entradas e processados pela função de soma e o bias. Como mostra a Fig. 23.




Fig. 23 - Modelo de um neurônio artificial.

- **Forward Propagation**

Uma rede de multicamadas é composta pela presença de inúmeros neurônios artificiais ligados em forma de camadas com interconexões, sendo que em cada camada podem existir diversos neurônios em paralelo de forma que a saída dos neurônios de cada camada são as entradas dos neurônios da camada subsequente, desde a camada de entrada até a camada de saída. Neste tipo de rede a propagação do processamento neural é unidirecional, e não existe retro-alimentações, ou seja, não existe a compensação dos pesos a fim de se obter uma otimização da saída desejada. Este tipo de propagação é chamado de Forward Propagation, e é comumente utilizado após o treinamento das redes neurais, quando os coeficientes já foram otimizados, para a aplicação do modelo em novos dados de entrada. A Fig. 24 mostra um exemplo deste tipo de propagação na rede.




Fig. 24 - Exemplo de Forward Propagation.

- **Back Propagation**

Durante o treinamento supervisionado de uma rede neural, comumente é necessária a utilização de técnicas para se ajustar os valores dos pesos da rede, a partir de um conjunto conhecido de vetores de entrada, a fim de se obter os melhores valores de pesos para a rede que aproximem os valores da saída da rede aos valores de um vetor de saídas desejadas. Uma das técnicas é a utilização de um algoritmo de backpropagation, onde é apresentado a rede um conjunto de dados de treinamento, com pares de entrada e saída conhecidos. O vetor de entrada é propagado camada a camada, até a camada de saída. O vetor de saída da rede é então comparado ao vetor de saída conhecido, e a diferença entre ambos é o erro de saída da rede.

Este erro é então retro-propagado pela rede, a fim de ajustar os pesos para que a próxima iteração, o erro de saída seja reduzido. Esse processo é repetido para todos os pares de conjunto de treinamento da rede, até que o erro de saída aceitável seja atingido, e assim, a condição de parada do treinamento seja verdadeira.

- **Simulink**

Para esse experimento, foi utilizada a ferramenta de simulação Simulink, presente no software MATLAB versão R2016. Como explicado na sessão de geração do dataset, esta ferramenta permite a criação de sistemas em formato de blocos, e possui modelos de blocos que auxiliaram na criação do sistema proposto, por disponibilizar exemplos de painéis solares com características reais, que foram utilizados para se fazer a criação do banco de dados e a validação do sistema.

Com a geração do dataset através de valores aleatórios de temperaturas e irradiâncias, e com o auxílio da ferramenta Jupyter Notebook e da biblioteca scikit learn, foi possível se realizar o treinamento da rede neural que seria utilizada no projeto através da linguagem de programação Python. Portanto, o banco de dados gerado foi importado na ferramenta de desenvolvimento em Python, após isso, o banco de dados foi dividido em treinamento e testes, logo em seguida o modelo de rede neural foi definido e treinado, em seguida foi verificado o desempenho do modelo no conjunto de teste. Tendo sido obtido um bom desempenho no conjunto de teste, os coeficientes de pesos e bias da rede neural foram exportados para que pudessem ser usados novamente no MATLAB.

Por fim, foi criado um novo sistema de simulação no Simulink, substituindo-se o bloco que gerava a função perturba e observa para a geração dos dados, por um bloco que implementa a forward propagation da rede neural obtida em Python. A Fig. 25 mostra o sistema montado para a validação dos coeficientes da rede neural.

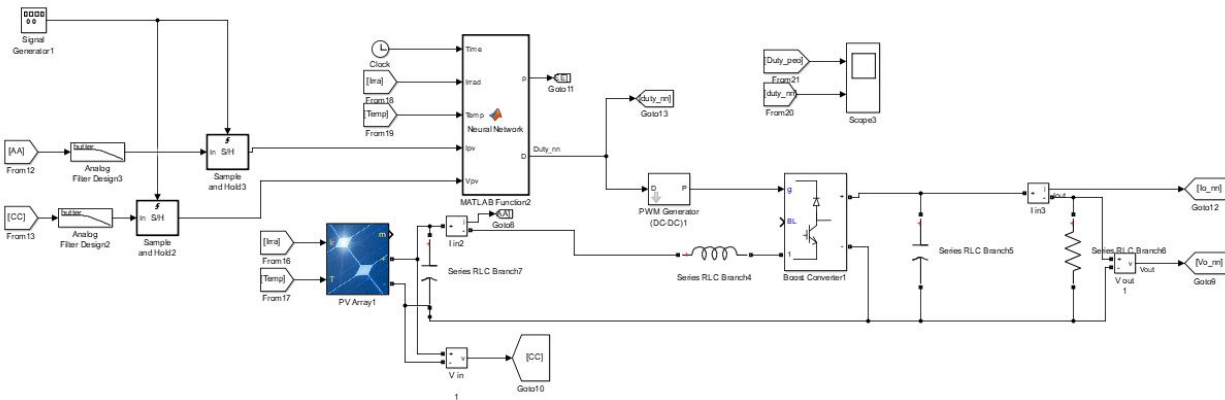


Fig. 25 - Implementação da rede neural no sistema através do Simulink

Portanto, comparou-se os resultados gerados de duty cycle e consequentemente da potência de saída, entre a rede neural e o algoritmo de perturba e observa, a fim de se realizar uma comparação entre os métodos. Os resultados obtidos serão discutidos na próxima sessão.

Resultados

Como foi discutido anteriormente, através da ferramenta Simulink presente no software MATLAB, foi possível se verificar o funcionamento de um sistema de MPPT através do método perturba e observa, e compará-lo com diferentes redes neurais a fim de se levantar a melhor solução para este problema. Portanto, para efeito de repetibilidade, todos os testes presentes nesta sessão foram realizados com simulações de 3 segundos de duração, e compararam as potências e o duty cycle dos métodos perturba e observa (em amarelo) e da rede neural (em azul) e são mostrados nas imagens abaixo para diferente modelos de rede neural.

O primeiro teste não trouxe resultados muito satisfatório, pois foi realizado com uma rede de duas camadas com quatro neurônios em cada camada, o que não conseguiu aproximar corretamente o valor de duty cycle como mostra a fig. 26.




Fig. 26 - Primeiro teste com rede neural de 2 camadas sendo cada uma com 4 layers.

Uma outra simulação que não foi muito bem sucedida foi a tentativa de se utilizar uma ativação na rede neural do tipo ReLu, devido ao fato de o Simulink não reconhecer a função que causa este tipo de ativação como função nativa, existia a necessidade de importá-la durante a simulação o que pode ter causado um erro na predição da rede, já que durante o treinamento e o teste a acurácia da rede gerada foi boa

- **Simulação com 3 camadas e 150 neurônios, ativação Relu, score de 99,46%**




Fig. 27 - Comparação de potência com ativação ReLu




Fig. 28 - Comparação de duty cycle com ativação ReLu

- Simulação com 3 camadas e 150 neurônios, ativação Tanh, score de 99,48%




Fig. 29 - Comparação de potência com 3 camadas de 150 neurônios cada




Fig. 30 - Detalhe da melhora da resposta ao transiente utilizando redes neurais




Fig. 31 - Comparação de duty cycle com 3 camadas de 150 neurônios cada




Fig. 32 - Detalhe da melhora da resposta ao transiente utilizando redes neurais

É importante notar a melhora da resposta do sistema, a um transiente com a utilização de redes neurais, em comparação com a técnica de perturba e observa, devido ao fato de que a rede neural não procura pelo duty cycle ótimo e sim prevê ele com base em dados anteriores.

- **Simulação com 3 camadas e 10 neurônios, ativação Tanh, score de 99,35%**




Fig. 32 - Comparação de potência com 3 camadas de 10 neurônios cada




Fig. 33 - Comparação de duty cycle com 3 camadas de 10 neurônios cada

- **Simulação com 3 camadas e 50 neurônios, ativação Tanh, score de 99,40%**




Fig. 32 - Comparação de potência com 3 camadas de 50 neurônios cada



Fig. 35 - Comparação de duty cycle com 3 camadas de 50 neurônios cada

- **Simulação com 3 camadas e 75 neurônios, ativação Tanh, score de 98,20%**
Com entradas apenas Irradiancia e Temperatura




Fig. 36 - Comparação de potência com 3 camadas de 75 neurônios cada e apenas 2 entradas




Fig. 37 - Comparação de duty cycle com 3 camadas de 75 neurônios cada e apenas duas entradas

- Simulação com 2 camadas e 250 neurônios, ativação Tanh, score de 99,27%




Fig. 38 - Comparação de duty cycle com 2 camadas de 250 neurônios cada




Fig. 39 - Comparação de potência com 2 camadas de 250 neurônios cada

- Simulação com 10 camadas e 50 neurônios, ativação Tanh, score de 99,39%




Fig. 40 - Comparação de potência com 10 camadas de 50 neurônios cada




Fig. 41 - Comparação de potência com 10 camadas de 50 neurônios cada

Conclusão

Os experimentos desenvolvidos mostram que as redes neurais podem ser uma boa alternativa para as técnicas tradicionais utilizadas em sistemas de MPPT em painéis solares, já que podem possuir uma boa precisão e obter resultados com respostas até melhores ao método perturba e observa se comparadas as respostas das duas técnicas em relação aos transientes de entrada. Porém existe um trade-off em relação a dificuldade de implantação de redes neurais nesse tipo de aplicação, já que exige um maior esforço durante o treinamento, e um maior processamento durante a implementação de novas predições.

Dentre os resultados obtidos, alguns foram bons e outros não tão satisfatórios.

- Com relação a função de ativação a Tanh teve um desempenho considerável melhor que a Relu, não conseguimos treinar uma boa rede que funciona-se com ativação Relu.
- Quando treinamos redes com 3 hidden layer só obtivemos resultados satisfatórios quando a rede era tinha mais de 50 neurônios, esse teste foi feito com 10 25 35 50 150.
- O painel influencia no treinamento, caso fosse necessário usar outro painel seria necessário gerar um novo data-set ou talvez fazer alguma calibração no data-set
- Melhorias no sistema podem ser obtidas para se generalizar a adição de redes com diferentes tamanhos de camadas e diferentes ativações para se verificar o comportamento nestas condições.
- Devido a demora no tempo de simulação e a dificuldade de se importar funções externas ao Simulink não foi possível se realizar simulações durante um grande período de tempo com diversos parâmetros diferentes.

Referencias:

- [1] N. Khaldi, H. Mahmoudi, M. Zazi and Y. Barradi, "The MPPT control of PV system by using neural networks based on Newton Raphson method," *2014 International Renewable and Sustainable Energy Conference (IRSEC)*, Ouarzazate, 2014, pp. 19-24. doi: 10.1109/IRSEC.2014.7059894
- [2] S. Messalti, A. G. Harrag and A. E. Loukriz, "A new neural networks MPPT controller for PV systems," *IREC2015 The Sixth International Renewable Energy Congress*, Sousse, 2015, pp. 1-6. doi: 10.1109/IREC.2015.7110907
- [3] I. Chtouki, P. Wira and M. Zazi, "Comparison of several neural network perturb and observe MPPT methods for photovoltaic applications," *2018 IEEE International Conference on Industrial Technology (ICIT)*, Lyon, 2018, pp. 909-914. doi: 10.1109/ICIT.2018.8352299
- [4] K. Jyotheeswara Reddy and N. Sudhakar, "High Voltage Gain Interleaved Boost Converter With Neural Network Based MPPT Controller for Fuel Cell Based Electric Vehicle Applications," in *IEEE Access*, vol. 6, pp. 3899-3908, 2018. doi: 10.1109/ACCESS.2017.2785832
- [5] R. Benkercha, S. Moulahoum and N. Kabache, "Combination of artificial neural network and flower pollination algorithm to model fuzzy logic MPPT controller for photovoltaic systems," *2017 18th International Symposium on Electromagnetic Fields in Mechatronics, Electrical and Electronic Engineering (ISEF) Book of Abstracts*, Lodz, 2017, pp. 1-2. doi: 10.1109/ISEF.2017.8090701